

T326 - Ciência de Dados

Rafael da Silva Albuquerque - 2518062

Universidade de Fortaleza

Relatório Técnico - Aprendizado de Máquina

Dataset escolhido:


- [UrbanTrace: Lifestyle & Pollution Insights](#)







Modelos aplicados:


- Classificação: Floresta Aleatória;
- Regressão: Regressão Linear.

Análise Exploratória de Dados

A fim de visualizar a distribuição dos dados e identificar necessidades de pré-processamento, plotei histogramas de cada coluna:








Então, categorizei as colunas de acordo com tipo (numérica, categórica), cardinalidade (para categóricas), e distribuição:

Coluna	Tipo	Cardinalidade	Distribuição
daily_travel_time	Numérica	-	Normal
vehicle_ownership	Categórica	3	Uniforme
location_type	Categórica	3	Multinomial ~(50%, 30%, 20%)
nearby_industries	Numérica	-	Normal
green_space_access	Categórica	3	Multinomial ~(50%, 30%, 20%)
home_air_quality	Numérica	-	Normal
work_location_type	Categórica	4	Uniforme
smoker_in_household	Categórica	2	Multinomial ~(80%, 20%)
noise_pollution_level	Numérica	-	Normal
use_of_air_purifiers	Categórica	2	Multinomial ~(70%, 30%)
awareness_level	Categórica	3	Multinomial ~(40%, 30%, 30%)
years_in_location	Numérica	-	Uniforme
pollution_exposure_score	Numérica	-	Normal
risk_category	Categórica	3	Multinomial ~(85%, 12%, 3%)

Correlação entre variáveis




Nota-se que algumas variáveis têm correlação maior com *pollution_exposure_score*, como *daily_travel_time*, *vehicle_ownership*, *location_type*, *nearby_industries*, *home_air_quality* e *work_location_type*.


Para *risk_category*, nenhuma variável individual se destaca em sua correlação.

É possível observar também que nenhuma variável é fortemente correlacionada com outra variável, o que elimina a possibilidade de **colinearidade**.

Seria possível determinar a categoria de risco simplesmente utilizando *pollution_exposure_score*, mas essa relação será ignorada já que ambas são colunas de *target* para diferentes tarefas, e não de *feature*.



Além disso, o conjunto de dados contém uma grande quantidade de valores nulos.



Classificação

Pré-processamento

- **Colunas numéricas** (*daily_travel_time*, *nearby_industries*, *home_air_quality*, *noise_pollution_level*, *years_in_location*): **padronização** estatística, que centra os dados no eixo y e de modo que a média seja igual a 0 e o desvio padrão igual a 1;
- **Colunas categóricas** (*vehicle_ownership*, *location_type*, *green_space_access*, *work_location_type*, *awareness_level*): **codificação ordinal**, que substitui os valores de texto em equivalentes numéricos do tipo inteiro e mantém igual o número de colunas. Ex: (Baixo, médio, alto) -> (0, 1, 2). Se fosse aplicado o *one-hot encoding*, o número de colunas crescería e isso tornaria a floresta aleatória menos eficiente;
- **Valores nulos: Imputação com KNN**, para os 5 vizinhos mais próximos.

Treinamento

1. Divisão dos dados entre treino e teste com proporção de 80/20;

2. **Grid Search Cross-Validation:** pontuação por **f1_macro**;

```
grid_search_params = {  
    'classifier__n_estimators': [100, 200],  
    'classifier__max_depth': [10, 20],  
    'classifier__min_samples_leaf': [5, 10],  
    'classifier__class_weight': ['balanced', 'balanced_subsample'],  
    'classifier__criterion': ['entropy']  
}
```

3. Execução do ajuste, que totalizou 80 iterações do *grid search*.


	param_classifier__n_estimators	param_classifier__max_depth	param_classifier__min_samples_leaf	param_classifier__class_weight	param_classifier__criterion	mean_test_score
7	200	20	10	balanced	entropy	0.724118
6	100	20	10	balanced	entropy	0.723388
14	100	20	10	balanced_subsample	entropy	0.719108
15	200	20	10	balanced_subsample	entropy	0.719053
12	100	20	5	balanced_subsample	entropy	0.711317
2	100	10	10	balanced	entropy	0.711113
5	200	20	5	balanced	entropy	0.709999
3	200	10	10	balanced	entropy	0.709714
13	200	20	5	balanced_subsample	entropy	0.707066
0	100	10	5	balanced	entropy	0.705955

10 melhores estimadores resultantes do *grid search*.

Resultados

	precision	recall	f1-score	support
High	0.52	0.56	0.54	43
Low	0.61	0.79	0.69	240
Medium	0.96	0.92	0.94	1717
accuracy	-	-	0.89	2000
macro avg	0.70	0.75	0.72	2000
weighted avg	0.91	0.89	0.90	2000

Confusion Matrix for Random Forest Classifier with Best Parameters



Interpretação dos resultados

Apesar de o modelo ter atingido um f1-macro de 0.72, é possível identificar pelo relatório de classificação e pela matriz de confusão que a desigualdade entre as classes no conjunto de treinamento levou o modelo a ser bem menos preciso em classificar a classe *High* que as outras, sendo razoável na classe *Low* e preciso na classe *Medium*.

Isso abre a possibilidade de atingir melhores resultados aplicando amostragem sintética no conjunto de treinamento, para balancear as classes.

Regressão

Pré-processamento


- **Colunas numéricas** (*daily_travel_time*, *nearby_industries*, *home_air_quality*, *noise_pollution_level*, *years_in_location*): **padronização** estatística, que centraiza os dados no eixo y e de modo que a média seja igual a 0 e o desvio padrão igual a 1;
- **Colunas categóricas** (*vehicle_ownership*, *location_type*, *green_space_access*, *work_location_type*, *awareness_level*): **one-hot encoding**, que substitui os valores de texto em equivalentes numéricos do tipo inteiro, substituindo a coluna de cardinalidade k por $k - 1$ colunas binárias;
- **Valores nulos: Imputação com KNN**, para os 5 vizinhos mais próximos, em colunas numéricas;

- **Valores nulos: Imputação Simples**, com a estratégia de valor mais frequente, em colunas categóricas.

Treinamento

1. Divisão dos dados em treino e teste, com proporção de 80/20;
2. **K-fold Cross-Validation**: com $k = 5$, avaliando com a métrica R_2 ;
3. Execução do ajuste.

Resultados



Métricas no conjunto de teste:

Erro quadrático médio (MSE)	28.2686
Raiz quadrada do erro quadrático médio (RMSE)	5.3168
R_2	0.8084

Interpretação

Atingindo um R_2 de 0.8084 no conjunto de teste, pode-se afirmar que o modelo se ajustou bem aos dados e com RMSE igual a 5.3168, é possível constatar que o modelo tende a ser preciso em suas predições.

No entanto, o gráfico de “Distribuição de erro de predição” demonstra que o modelo erra em distribuição normal, e o gráfico de “Erro quadrático média por faixa de valor real” indica que o modelo tende a errar quando se aproxima da faixa com menos valores no conjunto de treinamento.